

Faculdade de Informática e Administração Paulista

RELATÓRIO EXECUTIVO

Tech Challenge



Pos Tech - Data Analytics: 2026


Faculdade de Informática e Administração Paulista

RELATÓRIO EXECUTIVO

Classificação da Qualidade de Vinhos com Machine Learning



Wine Quality Analysis Using Machine Learning Techniques



Tech Challenge: Fase 2

Integrantes do grupo:

Ana Paula Machado Condessa - rm373492

Jhennifer Aparecida Oliveira Freitas - rm370853

Lucas Henrique da Silva Cruz - rm374131

Pedro Paulo Goes Alves- rm370771

João Vicente da Rosa da Silveira - rm372552

Sumário

Introdução.....	4
Contextualização inicial: como a qualidade de um vinho é apurada?.....	6
Desafio da indústria do vinho.....	6
A ciência sobre a qualidade dos vinhos.....	6
Transformando uma avaliação subjetiva em um problema de dados para apoiar a tomada de decisão.....	7
O principal insight da análise exploratória.....	7
Insight executivo.....	8
O que diferencia um vinho de alta qualidade?.....	8
Warm up: storytelling.....	9
Enfoque da Análise.....	10
Base de dados e definição da variável alvo.....	11
Análise exploratória dos dados (EDA).....	12
Como o Machine Learning agrega valor?.....	12
Correlações e leitura dos indicadores.....	13
Outliers e pré-processamento.....	14
Modelagem preditiva.....	15
Avaliação dos modelos.....	16
Comparação visual dos modelos.....	17
Discussão das métricas e escolha do modelo.....	18
Importância das variáveis.....	19
Interpretação executiva dos fatores.....	20
Implicações para o processo produtivo.....	21
Recomendações para diretoria.....	22
Recomendações técnicas e governança.....	23
Plano de implantação.....	24
Storytelling para apresentação e vídeo.....	25
Entregáveis e softwares utilizados.....	26
Resultados principais do projeto.....	27
Conclusão executiva.....	28
Anexo I - Indicadores e Métricas do Projeto.....	29
Anexo II - Detalhamento dos Modelos.....	30
Anexo III - Análise detalhada do projeto.....	31
Preparação da variável alvo.....	31
Análise exploratória dos dados.....	31
Análise de correlação.....	32
Análise de outliers.....	32
Pré-processamento dos dados.....	33
Modelos treinados.....	33
Avaliação dos modelos.....	34
Escolha do modelo final.....	35
Interpretação das variáveis mais importantes.....	35
Implicações para o processo produtivo.....	36
Conclusão.....	36
Limitações e Trabalhos Futuros.....	38
Referências.....	39

Introdução

Este relatório apresenta a análise executiva do projeto de classificação da qualidade de vinhos desenvolvido atendendo à proposta do Tech Challenge da fase dois da pós-tech da Fiap. O trabalho utiliza dados físico-químicos de amostras de vinho para construir modelos capazes de identificar se uma amostra pertence aos grupos de alta, média ou baixa qualidade.

O relatório foi organizado para atender a dois objetivos simultâneos: servir como documento técnico de apoio à avaliação do projeto e servir de base para uma apresentação executiva. O público-alvo é formado por professores, avaliadores e lideranças de uma empresa vitivinícola interessada em utilizar ciência de dados como ferramenta complementar ao processo tradicional de avaliação da qualidade dos vinhos.

A qualidade de um vinho é historicamente avaliada por especialistas por meio de análises sensoriais. Nesse processo, fatores como aroma, sabor, acidez, equilíbrio, corpo e persistência são observados de forma integrada. Apesar de ser uma etapa essencial para a indústria vitivinícola, essa avaliação pode ser subjetiva, demorada e dependente da experiência individual dos avaliadores.

O avanço das técnicas de ciência de dados e aprendizado de máquina permite complementar esse processo com uma abordagem analítica. A partir de variáveis físico-químicas coletadas durante a produção, é possível identificar padrões associados a vinhos melhor avaliados e criar modelos preditivos que apoiem a tomada de decisão.

Neste projeto, a variável de qualidade original foi convertida em uma variável binária. Vinhos com nota maior ou igual a 7 foram classificados como de alta qualidade, enquanto vinhos com nota menor que 7 foram classificados como de baixa ou média qualidade. Assim, transformamos o problema em uma tarefa de classificação, alinhada ao objetivo de identificar amostras com maior potencial de avaliação positiva.

A proposta deste relatório é apresentar a jornada completa da análise, desde a compreensão do problema, incluindo a interpretação dos resultados, bem como recomendações para aplicação prática no processo produtivo.

Desta forma, nossa abordagem baseou-se em dados para apoiar a classificação da qualidade dos vinhos. A proposta foi desenvolver modelos de

Machine Learning capazes de prever se um vinho possui alta, média ou baixa qualidade a partir de características físico-químicas obtidas durante o processo produtivo.

A base utilizada contém variáveis como acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos, teor alcoólico e nota de qualidade atribuída por especialistas.

Contextualização inicial: como a qualidade de um vinho é apurada?

Tradicionalmente, a qualidade de um vinho é determinada por especialistas (enólogos e sommeliers) através de análises sensoriais. Eles avaliam aspectos como:

- Equilíbrio entre álcool, acidez, açúcar e taninos;
- Complexidade aromática;
- Corpo do vinho;
- Persistência dos aromas e sabores após a degustação;
- Ausência de defeitos sensoriais.

De acordo com os principais sistemas internacionais de avaliação, os vinhos recebem notas geralmente entre 50 e 100 pontos. Quanto maior a nota, maior a percepção de qualidade daquele vinho.

O problema é que esse processo possui um componente subjetivo. Ou seja, dois especialistas experientes podem ter percepções ligeiramente diferentes sobre o mesmo vinho. E foi justamente para complementar essa análise humana que surgiu a proposta deste projeto.

Desafio da indústria do vinho

Imagine uma vinícola produzindo milhares de garrafas por safra. A avaliação sensorial é indispensável, mas ela ocorre normalmente após grande parte do processo produtivo já ter acontecido. Assim, nossa pergunta estratégica passa a ser se seria possível prever a qualidade de um vinho antes mesmo da degustação final, utilizando apenas dados laboratoriais? E essa é a pergunta central do nosso projeto.

A ciência sobre a qualidade dos vinhos

A química do vinho influencia diretamente a experiência sensorial. Por isso, diversos estudos mostram que fatores como: teor alcoólico; acidez volátil; ácido cítrico; sulfatos; densidade e pH; afetam as características percebidas pelo consumidor, como corpo, frescor, equilíbrio e estabilidade do produto.

Em outras palavras, antes de ser percebida pelo paladar, a qualidade do vinho já deixa sinais mensuráveis em sua composição química. E foi essa a hipótese que guiou a nossa análise.

Transformando uma avaliação subjetiva em um problema de dados para apoiar a tomada de decisão

Os especialistas já haviam atribuído notas aos vinhos. A estratégia adotada foi converter essas notas em uma pergunta simples de negócio:

O vinho possui alta qualidade ou não? Dessa forma fizemos a seguinte separação dos dados

- Nota $\geq 7 \rightarrow$ Alta qualidade
- Nota $< 7 \rightarrow$ Baixa/Média qualidade

Essa decisão simplifica o problema e aproxima o modelo de uma aplicação prática para a indústria.

O principal insight da análise exploratória

A maioria dos vinhos da base recebeu notas intermediárias. Isso revela um cenário muito semelhante ao mundo real em que:

vinhos medianos são comuns.

vinhos excelentes são raros.

Esse foi o primeiro grande insight do projeto. Não nos bastaria criar um modelo que acertasse a maioria dos casos. Foi necessário identificar justamente os vinhos de alta qualidade, que representam a menor parcela da base.

Insight executivo

A qualidade não depende de uma única característica. O que diferencia os melhores vinhos é o equilíbrio entre diversos componentes físico-químicos. Esse resultado reforça exatamente o que os especialistas observam durante uma degustação.

O que diferencia um vinho de alta qualidade?

Quando analisamos as correlações e a importância das variáveis, surgiu um padrão interessante. Os fatores mais relevantes foram:

Variável	Descrição
Álcool	corpo e intensidade
Ácido cítrico	frescor e equilíbrio
Sulfatos	estabilidade e conservação
Acidez volátil	possíveis defeitos sensoriais
Densidade	estrutura geral do vinho

Warm up: storytelling

A história central deste projeto parte de uma pergunta simples: é possível antecipar a qualidade de um vinho a partir de sua composição e características físico-químicas? A resposta encontrada pela análise é positiva, mas com ressalvas importantes. Os modelos não substituem a avaliação sensorial dos especialistas, mas conseguem identificar combinações de variáveis que diferenciam vinhos de alta qualidade dos demais.

A base analisada indica um desafio comum de classificação: a maior parte das amostras está concentrada em notas intermediárias. Isso significa que a classe de alta qualidade é menor, o que torna o problema desbalanceado. Sob a ótica de negócio, esse detalhe é relevante porque um modelo que apenas acerta a classe majoritária pode apresentar boa acurácia, mas pouca utilidade para identificar os vinhos realmente superiores.

Por essa razão, a narrativa do projeto não se limita a apontar qual modelo acertou mais. Ela busca explicar qual modelo apresentou melhor equilíbrio entre identificar vinhos de alta qualidade e evitar classificações incorretas. Esse equilíbrio é fundamental para que a ferramenta seja usada como apoio à decisão, sem gerar confiança excessiva em previsões pouco precisas.

O storytelling, portanto, será conduzido em três movimentos: primeiro, compreender os dados; segundo, testar modelos preditivos; terceiro, transformar resultados técnicos em sugestões para o aprimoramento do processo de produção do vinho.

Enfoque da Análise

O foco prioritário da análise foi entender o quanto a composição química e as características físico-químicas influenciam a produção de vinhos de alta qualidade. A meta não foi apenas construir um modelo com bom desempenho estatístico, mas também proporcionar uma compreensão melhor da influência dessas variáveis no processo de produção para um público executivo.

Foram avaliados quatro blocos de informação. O primeiro bloco compreende a distribuição das notas e o balanceamento entre as classes. O segundo bloco trata da verificação de correlações entre variáveis, buscando identificar relações relevantes. O terceiro bloco aborda a presença de outliers e a verificação da qualidade dos dados de maneira geral. O quarto bloco apresenta a modelagem e a avaliação comparativa dos algoritmos.

Do ponto de vista gerencial, as perguntas norteadoras foram: quais fatores influenciam de forma mais significativa a obtenção de alta qualidade do produto? Qual foi o modelo que apresentou melhores resultados? Quais decisões de produção podem ser apoiadas pela análise desenvolvida? E quais cuidados devem ser tomados antes de transformar o modelo em uma ferramenta operacional?

Base de dados e definição da variável alvo

A base utilizada contém amostras de vinho descritas por variáveis físico-químicas. Entre elas estão acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos, teor alcoólico e qualidade do vinho.

A variável original de qualidade representa uma nota atribuída por especialistas. Para atender ao objetivo do desafio, essa variável foi transformada em uma variável binária chamada `high_quality`.

A regra utilizada foi considerar vinho de alta qualidade aqueles que foram atribuídas notas maiores ou iguais a 7 e de baixa ou média qualidade para notas menores que 7.

Essa transformação é uma decisão metodológica importante. Em vez de prever a nota exata, o modelo passa a responder a uma pergunta de negócio mais direta: esta amostra tem perfil de vinho de alta qualidade? Essa abordagem torna a interpretação mais simples para o público executivo e permite aplicar métricas específicas de classificação.

Campo	Tratamento	Justificativa
quality	usada para criar a classe binária	nota original atribuída ao vinho
high_quality	variável alvo do modelo	representa a classificação final
Id	removida da modelagem	identificador não preditivo
variáveis físico-químicas	mantidas como variáveis explicativas	características disponíveis para a previsão

Análise exploratória dos dados (EDA)

A análise exploratória (EDA) teve como objetivo compreender o comportamento das variáveis antes do treinamento dos modelos. A primeira leitura relevante foi a distribuição das notas de qualidade. A concentração em notas intermediárias indica que a base contém majoritariamente vinhos avaliados como de baixa ou média qualidade.

A transformação para classificação binária reforçou essa leitura. A classe de alta qualidade representa uma parcela menor da base, apontando um problema de desbalanceamento. Em termos práticos, essa constatação indica a necessidade de um certo cuidado na escolha das métricas de avaliação, pois a acurácia pode superestimar a qualidade do modelo.

Também foram analisadas as distribuições das variáveis físico-químicas. Algumas delas tendem a apresentar maior dispersão e valores extremos, o que é esperado em dados reais de produção. Essa etapa contribuiu para orientar as decisões de pré-processamento e para evitar interpretações equivocadas.

A principal conclusão da EDA é que o problema não deve ser tratado como uma classificação simples baseada somente em acertos totais. O foco deve estar na capacidade de identificar corretamente os vinhos de alta qualidade, sem aumentar excessivamente a quantidade de falsos positivos.

Como o Machine Learning agrega valor?

O modelo não aprende "o que é um vinho bom". Ele aprende quais combinações de características químicas costumam estar presentes nos vinhos que os especialistas classificaram como bons.

Essa é uma distinção importante. O algoritmo não substitui o conhecimento do enólogo. Ele captura padrões históricos das características monitoradas que auxiliam na identificação de um vinho de alta qualidade.

Correlações e leitura dos indicadores

A análise de correlação foi utilizada para identificar associações entre a composição do produto, as variáveis físico-químicas e a qualidade do vinho. Correlações ajudam a revelar relacionamentos, mas não devem ser interpretadas como prova de causalidade.

Variáveis como teor alcoólico, ácido cítrico, sulfatos, acidez volátil e densidade se destacaram na interpretação geral do projeto. O teor alcoólico apareceu como um dos principais fatores associados a vinhos de alta qualidade. Ácido cítrico e sulfatos também foram relevantes, indicando relação com equilíbrio, frescor e estabilidade química.

A acidez volátil merece uma atenção específica, já que, quando em níveis elevados, ela pode estar associada a características sensoriais indesejadas. Por isso, mesmo quando aparece como uma variável importante, sua leitura deve considerar o sentido da sua relação com a qualidade (o modo como influencia). Densidade também tem papel relevante por refletir aspectos da composição geral do vinho.

A interpretação executiva é que a qualidade percebida não parece depender de um único fator isolado, mas de um conjunto de características que, combinadas, formam o perfil de composição e características físico-químicas de um vinho melhor avaliado.

Outliers e pré-processamento

A etapa de outliers buscou identificar valores muito distantes do comportamento geral das variáveis. Em dados físico-químicos, valores extremos podem ocorrer por diferentes motivos: variação natural do processo produtivo, características específicas de determinados lotes ou possíveis inconsistências no processo de coleta.

A decisão adotada foi não remover automaticamente os outliers. Essa escolha é coerente com a natureza do problema, pois excluir amostras extremas sem investigação poderia eliminar informações relevantes sobre vinhos com perfis incomuns. Além disso, modelos baseados em árvores, como Random Forest, tendem a ser menos sensíveis a valores extremos do que modelos lineares.

No pré-processamento, a coluna “Id” foi removida por representar apenas um identificador. A variável “*quality*” também foi removida das variáveis explicativas porque deu origem à variável alvo.

Por fim, a divisão entre treino e teste foi feita de forma estratificada, preservando a proporção entre as classes. E a padronização foi aplicada no pipeline da Regressão Logística, evitando vazamento de dados e garantindo que o escalonamento fosse apreendido apenas como conjunto de treino.

Modelagem preditiva

Foram treinados três modelos de classificação: Regressão Logística, Random Forest e Gradient Boosting. A escolha desses modelos permitiu comparar uma abordagem linear, uma abordagem baseada em comitê de árvores e uma abordagem de aprendizado sequencial.

A Regressão Logística foi usada como modelo base. A vantagem deste modelo é a simplicidade e interpretabilidade, sendo bastante útil para criar uma referência inicial de desempenho. Já que esse modelo é sensível à escala das variáveis, foi utilizado o StandardScaler em um pipeline.

O Random Forest foi escolhido por sua capacidade de capturar relações não lineares e interações entre variáveis. Ele também oferece uma medida de importância das variáveis, o que facilita a interpretação dos fatores mais associados à classificação da qualidade.

O Gradient Boosting foi incluído como terceiro modelo para ampliar a comparação. Esse algoritmo cria modelos em sequência, tentando corrigir erros anteriores. Em muitos problemas tabulares, pode apresentar um bom desempenho, embora ele exija um cuidado com o ajuste de parâmetros e ofereça um risco de sobreajuste.

- Regressão Logística: referência simples e interpretável.
- Random Forest: melhor equilíbrio entre desempenho e interpretação.
- Gradient Boosting: alternativa robusta para capturar padrões complexos.

Avaliação dos modelos

A avaliação dos modelos considerou um conjunto de métricas apropriadas para classificação binária. A acurácia mostra a proporção total de acertos, mas não é suficiente em bases desbalanceadas. Por isso, também foram avaliados precision, recall, F1-score e ROC-AUC.

A precisão indica, entre os vinhos previstos como de alta qualidade, quantos realmente eram de alta qualidade. A métrica recall indica, entre todos os vinhos de alta qualidade, quantos o modelo conseguiu identificar. Já o F1-score combina precisão e recall em uma única métrica. Por fim, a métrica ROC-AUC avalia a capacidade geral do modelo de separar as duas classes.

Modelo	Acurácia	Precision	Recall	F1-score	ROC-AUC
Regressão Logística	79.9%	37.9%	68.8%	48.9%	85.0%
Random Forest	91.7%	74.1%	62.5%	67.8%	90.8%
Gradient Boosting	90.0%	68.0%	53.1%	59.6%	87.2%

Os resultados indicam que o Random Forest apresentou o melhor desempenho geral. Ele obteve maior acurácia, maior precisão, maior F1-score e maior ROC-AUC. A Regressão Logística teve recall superior, mas sua precisão foi baixa, o que indica que há uma maior quantidade de falsos positivos neste modelo.

Comparação visual dos modelos

A comparação visual das métricas reforça a superioridade do Random Forest no equilíbrio geral do desempenho. O gráfico abaixo mostra que esse modelo se destaca, principalmente, em acurácia, precisão, F1-score e ROC-AUC.




Figura 1 - Comparação das métricas dos modelos.

Fonte: elaboração própria no Google Colab.

Discussão das métricas e escolha do modelo

Embora a Regressão Logística tenha conseguido capturar uma proporção maior de vinhos de alta qualidade, ela também classificou incorretamente muitos vinhos comuns como de alta qualidade. Esse modelo apresenta, portanto um comportamento bastante indesejado, pois reduz a confiança na recomendação.

O Random Forest apresentou acurácia de 91,7%, precision de 74,1%, recall de 62,5%, F1-score de 67,8% e ROC-AUC de 90,8%. Esse conjunto de resultados indica uma boa capacidade de separação entre as classes e menor risco de classificar indevidamente vinhos de baixa ou média qualidade como de alta qualidade.

O Gradient Boosting também apresentou desempenho competitivo, com acurácia de 90,0% e ROC-AUC de 87,2%, mas ficou abaixo do Random Forest em F1-score. Isso sugere que, para a configuração testada, o modelo Random Forest oferece melhor equilíbrio.

O modelo final escolhido foi, portanto, o Random Forest. E a decisão foi baseada não apenas na maior acurácia, mas principalmente na combinação de F1-score, precision e ROC-AUC, métricas mais adequadas para o contexto de classes desbalanceadas.

Importância das variáveis

Uma vantagem importante do Random Forest é a possibilidade de avaliar a importância relativa das variáveis para a previsão. Essa leitura ajuda a transformar o modelo em uma ferramenta de inteligência de negócio, pois mostra quais características mais contribuíram para a classificação.




Figura 2 - Importância das variáveis no modelo Random Forest.
Fonte: elaboração própria no Google Colab

O teor alcoólico foi a variável mais importante, seguido por ácido cítrico, sulfatos, acidez volátil e densidade. Esses fatores estão fortemente associados ao corpo, equilíbrio, acidez, estabilidade química, que, por sua vez, são reconhecidamente determinantes na experiência sensorial que qualifica vinhos de alta qualidade.

Interpretação executiva dos fatores

O teor alcoólico aparece como o principal fator preditivo. Em termos sensoriais, o álcool pode estar relacionado ao corpo, à estrutura e à percepção de intensidade. Isso não significa que simplesmente ao aumentar o teor alcoólico produzimos um vinho de qualidade, mas indica que, na base analisada, essa variável ajuda a diferenciar vinhos melhor avaliados.

O ácido cítrico surge como o segundo fator mais relevante. Ele pode estar associado a frescor e equilíbrio, contribuindo para uma experiência sensorial mais positiva quando presente em níveis adequados. Os sulfatos, por sua vez, estão associados à estabilidade e conservação, elementos importantes para manter a qualidade do produto ao longo do tempo.

A acidez volátil também tem papel significativo, pois os níveis elevados podem indicar características indesejadas, prejudicando aroma e sabor. Por isso, seu controle é importante para reduzir riscos de deterioração perceptiva do vinho.

A densidade completa o grupo de variáveis mais relevantes. Ela pode refletir a composição geral do vinho, incluindo a relação com álcool e açúcar residual. Juntas, essas variáveis mostram que o modelo não depende de um único indicador, mas de um equilíbrio físico-químico mais amplo.

Variável	Importância
alcohol	0.223
citric acid	0.147
sulphatés	0.143
volatile acidity	0.113
density	0.069

Implicações para o processo produtivo

Os resultados sugerem que o modelo pode ser usado como ferramenta complementar ao controle de qualidade. Isso ocorre já que, durante a produção do vinho, as variáveis físico-químicas são medidas e acompanhadas. O modelo adiciona uma camada preditiva, permitindo estimar a probabilidade de uma amostra pertencer ao grupo de alta qualidade.

Na prática, isso pode apoiar enólogos e produtores em diferentes momentos. Antes da avaliação sensorial final, o modelo pode indicar lotes com maior potencial de qualidade. Também pode sinalizar amostras que merecem uma investigação adicional, especialmente quando apresentam combinações de variáveis associadas a uma menor qualidade.

A aplicação deve ser feita com cautela. O modelo foi treinado a partir de uma base histórica e não deve substituir o julgamento técnico. A função deste modelo então é a de atuar como um radar: indicar padrões, priorizar análises e apoiar decisões sobre ajustes no processo produtivo.

O maior valor executivo está na padronização. Ao combinar dados laboratoriais e classificação preditiva, a empresa pode reduzir subjetividade, melhorar rastreabilidade e criar um processo de melhoria contínua baseado em indicadores.

Recomendações para diretoria

Para a diretoria de uma empresa vitivinícola, a recomendação principal é tratar o modelo como ferramenta de apoio à decisão e não como substituto da avaliação sensorial. O uso adequado está em combinar a experiência dos especialistas com sinais quantitativos derivados das características físico-químicas.

Ou seja:

- criar um painel executivo com os principais fatores preditivos: álcool, ácido cítrico, sulfatos, acidez volátil e densidade;
- monitorar a proporção de lotes classificados como de alta qualidade ao longo do tempo;
- comparar as previsões do modelo com avaliações sensoriais reais para medir aderência;
- usar o modelo para priorizar amostras que exigem avaliação técnica mais detalhada;
- estabelecer metas de melhoria para variáveis críticas, respeitando limites enológicos e padrões de produto.

Essas recomendações permitem transformar a análise em rotina gerencial. O objetivo não é automatizar a decisão final, mas melhorar a qualidade das perguntas feitas ao processo produtivo.

A diretoria também deve considerar que a classificação de alta qualidade é menos frequente na base. Isso reforça a necessidade de acompanhar indicadores por safra, lote, tipo de vinho e origem da matéria-prima.

Recomendações técnicas e governança

Para que o modelo seja confiável em ambiente produtivo, recomenda-se estabelecer uma governança mínima de dados e dos modelos. Essa governança deve garantir que as variáveis coletadas mantenham o mesmo padrão de medição, que os dados sejam armazenados com qualidade e que as previsões sejam monitoradas ao longo do tempo. Assim, recomendamos o seguinte:

- registrar origem, data e método de coleta de cada amostra;
- validar dados faltantes, inconsistentes ou fora das faixas esperadas antes de prever;
- recalibrar o modelo periodicamente com novas amostras e novas avaliações sensoriais;
- acompanhar métricas do modelo por período para identificar perda de desempenho;
- manter logs de previsão, decisão tomada e resultado final observado.

Outro ponto importante é a definição do limiar de classificação. O modelo gera probabilidades, e a decisão de classificar um vinho como de alta qualidade pode variar conforme o apetite ao risco. Um limiar mais baixo aumenta o “recall”, mas pode gerar mais falsos positivos. Um limiar mais alto aumenta a “precisão”, mas pode deixar de identificar alguns vinhos bons.

Essa decisão deve ser orientada pelo negócio. Para uma triagem inicial, pode-se aceitar maior ‘recall’. Para uma recomendação comercial ou rotulagem de alta qualidade, deve-se priorizar maior precisão.

Plano de implantação

A implantação do modelo pode ser realizada em fases, reduzindo risco e permitindo aprendizado gradual. A primeira fase é analítica: consolidar base histórica, padronizar variáveis e validar o modelo com dados já conhecidos. Nessa etapa, o modelo ainda não influenciaria as decisões produtivas.

A segunda fase é de piloto. O modelo passa a gerar previsões para novas amostras, mas os resultados são comparados com a avaliação sensorial sem interferir na decisão final. O objetivo é medir aderência em condições reais e ajustar o limiar de classificação.

A terceira fase é de apoio operacional. As previsões passam a ser usadas para priorização de amostras, investigação de desvios e acompanhamento dos indicadores. A decisão final continua sob responsabilidade técnica dos especialistas.

A quarta fase é a de melhoria contínua. Com ela, novos dados são incorporados ao treinamento, as métricas são monitoradas e o modelo é reavaliado periodicamente. Essa abordagem evita que o modelo fique obsoleto quando mudarem processos, matéria-prima, safra ou perfil dos produtos. Recomendamos que sejam realizados os seguintes passos:

1. validação histórica do modelo;
2. piloto com novas amostras e comparação com especialistas;
3. uso como apoio operacional em controle de qualidade;
4. ciclo contínuo de monitoramento e retreinamento.

Storytelling para apresentação e vídeo

Para a apresentação executiva, recomenda-se uma narrativa simples e direta. A abertura deve destacar que a avaliação tradicional de vinhos é essencial, mas pode ser complementada com dados físico-químicos. Em seguida, deve-se explicar que o projeto transformou a nota de qualidade em uma classificação binária: alta qualidade ou baixa/média qualidade.

O segundo momento da apresentação deve evidenciar o desafio da base: poucos vinhos pertencem ao grupo de alta qualidade. Por isso, a avaliação dos modelos não se baseou apenas na acurácia. Foram consideradas métricas que medem o equilíbrio entre acertos, falsos positivos e capacidade de identificar a classe de interesse.

O terceiro momento deve apresentar os modelos testados e o resultado principal: o Random Forest foi escolhido por apresentar o melhor desempenho geral, com acurácia de 91,7%, F1-score de 67,8% e ROC-AUC de 90,8%.

Por fim, a apresentação deve traduzir as variáveis mais importantes em implicações de negócio. Teor alcoólico, ácido cítrico, sulfatos, acidez volátil e densidade devem ser apresentados como fatores associados ao perfil de vinhos de alta qualidade, sempre reforçando que o modelo apoia, mas não substitui, o julgamento dos especialistas.

Entregáveis e softwares utilizados

A entrega do projeto está disponível no repositório do [GitHub](#), contendo os códigos utilizados, a [base de dados](#), os resultados, o README, e a apresentação executiva e a estrutura conforme recomendada no projeto. Disponibilizamos também um vídeo executivo de até cinco minutos, com linguagem orientada aos decisores.

- O Google Colab foi utilizado para o desenvolvimento da análise e treinamento dos modelos com o uso dos seguintes instrumentos:

- Python: linguagem principal do projeto;
- Pandas e numpy: manipulação e preparação dos dados;
- Matplotlib e seaborn: visualização dos resultados;
- Scikit-learn: modelagem, pipelines, métricas e validação.

- O [GitHub: contém a organização e publicação dos códigos e entregáveis](#)

- [Relatório](#): apresenta a análise dos modelos, a explicação dos resultados e recomendações para o negócio.

- No [canva](#) foi feita a criação da apresentação executiva.
- Foram utilizados também o Google Meet e o OBS para a produção e gravação do vídeo final.

- [Youtube](#): com a gravação do vídeo final.

A pasta results contém as principais métricas dos modelos com comparação visual, a importância das variáveis, as matrizes de confusão, as curvas ROC, os gráficos exploratórios e as tabelas auxiliares.

Resultados principais do projeto

Após comparar os três modelos algoritmos:

- Regressão Logística
- Gradient Boosting
- Random Forest

O Random Forest apresentou o melhor equilíbrio entre precisão e capacidade de identificar vinhos de alta qualidade.

O resultado demonstra que a qualidade do vinho é influenciada por relações complexas entre as variáveis, algo que modelos baseados em árvores conseguem capturar melhor do que modelos lineares.

Conclusão executiva

A análise demonstrou que a qualidade percebida pelos especialistas possui forte relação com características físico-químicas mensuráveis ao longo do processo produtivo.

O modelo Random Forest foi capaz de identificar esses padrões com elevada capacidade preditiva, alcançando 91,7% de acurácia e ROC-AUC de 90,8%.

E ainda mais importante do que prever a qualidade, o projeto permitiu compreender quais fatores exercem maior influência sobre ela.

Os resultados mostram que variáveis relacionadas ao equilíbrio químico do vinho são especialmente o teor alcoólico, o ácido cítrico, os sulfatos, a acidez volátil e a densidade, que estão entre os principais indicadores associados aos vinhos melhor avaliados.

Dessa forma, o Machine Learning não deve ser visto como substituto da degustação especializada, mas como uma ferramenta complementar capaz de antecipar tendências de qualidade, apoiar decisões de produção, fortalecer a gestão baseada em dados na indústria vitivinícola.

Anexo I - Indicadores e Métricas do Projeto

Métrica	Definição	Relevância
Acurácia	Percentual geral de previsões corretas.	Boa leitura geral, mas limitada em bases desbalanceadas.
Precision	Entre os vinhos previstos como alta qualidade, quantos realmente eram alta qualidade	Importante para evitar falsos positivos.
Recall	Entre os vinhos realmente de alta qualidade, quantos foram identificados pelo modelo.	Importante para não perder vinhos de alta qualidade.
F1-score	Média harmônica entre precisão e recall.	Resume o equilíbrio entre precisão e recall.
ROC-AUC	Capacidade geral de separação entre as classes.	Compara modelos independentemente de um único limiar.

A interpretação conjunta dessas métricas foi essencial para a escolha do modelo final, como o Random Forest. A acurácia isolada poderia favorecer modelos que apenas acertam a classe majoritária. O F1-score e o ROC-AUC forneceram uma leitura mais equilibrada, adequada ao objetivo do desafio.

Em projetos de classificação de qualidade, a escolha da métrica deve estar alinhada ao custo do erro. Classificar um vinho comum como de alta qualidade pode gerar uma decisão comercial equivocada. Deixar de identificar um vinho de alta qualidade pode representar perda de oportunidade. Por isso, neste caso, o equilíbrio entre precisão e recall foi priorizado.

Anexo II - Detalhamento dos Modelos

Modelo	Papel no projeto	Ponto forte	Ponto de atenção
Regressão Logística	modelo base e interpretável	simplicidade e leitura direta	menor capacidade de capturar interações complexas
Random Forest	modelo final selecionado	captura relações não lineares e fornece importância de variáveis	menos transparente que modelos lineares
Gradient Boosting	modelo adicional de comparação	aprendizado sequencial e boa performance em dados tabulares	pode exigir ajuste fino de parâmetros

A Regressão Logística cumpriu o papel de baseline. O Random Forest entregou o melhor equilíbrio entre desempenho e interpretação. O Gradient Boosting teve desempenho competitivo, mas não superou o Random Forest nas principais métricas do projeto.

A escolha do Random Forest também é sustentada pela necessidade de comunicar os resultados para um público executivo. A importância das variáveis fornece uma ponte entre a modelagem e as recomendações para o processo produtivo.

Anexo III - Análise detalhada do projeto

O objetivo principal foi construir uma pipeline de análise e modelagem capaz de classificar os vinhos em duas categorias:

- Alta qualidade: vinhos com nota maior ou igual a 7;
- Baixa ou média qualidade: vinhos com nota menor que 7.

Dessa forma, o problema foi tratado como uma tarefa de classificação binária. Em vez de prever a nota exata do vinho, o modelo passou a prever se uma amostra pertence ou não ao grupo de vinhos de alta qualidade.

Preparação da variável alvo

A variável original “quality”, que representa a nota atribuída ao vinho, foi transformada em uma nova variável chamada de “high_quality”.

A regra adotada foi:

- high_quality = 1 para vinhos com quality ≥ 7 ;
- high_quality = 0 para vinhos com quality < 7 .

Essa transformação foi necessária para simplificar o problema e permitir o desenvolvimento de modelos de classificação binária.

A coluna Id foi removida da modelagem por representar apenas um identificador da amostra. A variável quality também foi removida das variáveis explicativas, pois ela deu origem à variável alvo. Mantê-la no modelo causaria vazamento de informação, já que o modelo teria acesso direto à nota usada para construir a classificação.

Análise exploratória dos dados

A análise exploratória teve como objetivo compreender o comportamento da base antes da etapa de modelagem.

Primeiramente, foi analisada a distribuição da variável “quality”. A maior parte dos vinhos está concentrada nas notas intermediárias, principalmente nas notas 5 e 6. Isso indica que a base possui predominância de vinhos avaliados como de baixa ou média qualidade.

Em seguida, foi analisada a variável binária “high_quality”. Essa análise mostrou que a classe de vinhos de alta qualidade é menor em relação à classe de

vinhos de baixa ou média qualidade. Portanto, o problema apresenta desbalanceamento de classes.

Esse ponto é importante porque, em bases desbalanceadas, a acurácia pode ser uma métrica enganosa. Um modelo poderia obter boa acurácia apenas classificando a maioria das amostras como pertencentes à classe majoritária. Por isso, a avaliação dos modelos considerou também precision, recall, F1-score e ROC-AUC.

A análise das variáveis físico-químicas também permitiu observar diferentes padrões de distribuição, dispersão e presença de valores extremos. Essas informações foram importantes para compreender melhor os dados e apoiar as decisões de pré-processamento e modelagem.

Análise de correlação

A matriz de correlação foi utilizada para identificar associações entre as variáveis físico-químicas e a qualidade do vinho.

Essa análise não tem o objetivo de provar causalidade, mas ajuda a identificar quais variáveis apresentam maior relação com a classificação de alta qualidade.

Entre as variáveis mais relevantes, destacaram-se teor alcoólico, ácido cítrico, sulfatos, acidez volátil e densidade.

O teor alcoólico apresentou forte importância para o modelo, sugerindo que essa variável contribui de forma relevante para diferenciar vinhos de alta qualidade dos demais vinhos. O ácido cítrico e os sulfatos também apareceram como variáveis relevantes, possivelmente por estarem ligados a aspectos como frescor, equilíbrio e estabilidade química do vinho.

A acidez volátil também foi importante. Em termos práticos, níveis elevados de acidez volátil podem estar associados a características sensoriais indesejadas, o que pode prejudicar a percepção de qualidade do vinho.

A densidade também contribuiu para a classificação, possivelmente por sua relação com teor alcoólico, açúcar residual e composição geral do produto.

Análise de outliers

Foram analisados possíveis outliers nas variáveis físico-químicas utilizando boxplots e o método do intervalo interquartil.

Foram identificados valores extremos em algumas variáveis, especialmente nas variáveis: açúcar residual, cloretos, acidez fixa, sulfatos, dióxido de enxofre total e densidade.

No entanto, os outliers não foram removidos automaticamente. Como os dados representam medições reais de características físico-químicas dos vinhos, esses valores podem refletir variações legítimas do processo produtivo.

Além disso, foi utilizado o modelo Random Forest, que tende a ser menos sensível a outliers do que modelos lineares tradicionais. Por isso, a decisão foi manter os valores extremos na base e considerar sua presença durante a interpretação dos resultados.

Pré-processamento dos dados

Antes do treinamento dos modelos, os dados foram preparados para a modelagem. Quanto às variáveis explicativas, elas foram compostas pelas características físico-químicas do vinho e a variável alvo foi a coluna “high_quality”.

A base foi dividida em dados de treino e teste. A divisão foi feita de forma estratificada, preservando a proporção entre vinhos de alta qualidade e vinhos de baixa/média qualidade nos dois conjuntos.

Esse cuidado foi importante porque a base é desbalanceada. Sem a estratificação, o conjunto de teste poderia ficar com uma proporção diferente de classes, prejudicando a avaliação dos modelos.

A padronização das variáveis foi aplicada no pipeline da Regressão Logística, pois esse modelo é sensível à escala das variáveis. Para os modelos baseados em árvores, como Random Forest e Gradient Boosting, a padronização não é obrigatória, pois esses modelos não dependem da escala das variáveis da mesma forma.

Modelos treinados

Foram treinados três modelos de classificação:

- Regressão Logística;
- Random Forest;
- Gradient Boosting.

A Regressão Logística foi utilizada como modelo base. Ela é simples, rápida e interpretável, sendo útil para estabelecer uma referência inicial de desempenho.

O Random Forest foi utilizado por sua capacidade de capturar relações não lineares entre as variáveis e por apresentar boa robustez em bases com variáveis numéricas.

O Gradient Boosting foi incluído como modelo adicional para comparação, pois também consegue capturar padrões complexos nos dados por meio de aprendizado sequencial.

A utilização de três modelos permitiu comparar diferentes abordagens e selecionar aquela com melhor equilíbrio entre desempenho e utilidade para o negócio.

Avaliação dos modelos

Os modelos foram avaliados com as seguintes métricas:

- Acurácia;
- Precision;
- Recall;
- F1-score;
- ROC-AUC;
- Matriz de confusão.

A Regressão Logística apresentou “acurácia” de aproximadamente 79,9%, “precisão” de 37,9%, “recall” de 68,8%, “F1-score” de 48,9% e “ROC-AUC” de 85,0%.

O Random Forest apresentou “acurácia” de aproximadamente 91,7%, “precisão” de 74,1%, “recall” de 62,5%, “F1-score” de 67,8% e “ROC-AUC” de 90,8%.

O Gradient Boosting apresentou “acurácia” de aproximadamente 90,0%, “precisão” de 68,0%, “recall” de 53,1%, “F1-score” de 59,6% e “ROC-AUC” de 87,2%.

Esses resultados mostram que o Random Forest apresentou o melhor desempenho geral. Ele obteve a maior “acurácia”, o maior “F1-score” e o maior “ROC-AUC” entre os modelos avaliados.

Embora a Regressão Logística tenha apresentado o maior “recall” para a classe de alta qualidade, sua precisão foi significativamente menor. Isso significa que ela encontrou mais vinhos de alta qualidade, mas também classificou incorretamente muitos vinhos de baixa/média qualidade como de alta qualidade.

O Random Forest apresentou melhor equilíbrio entre identificar corretamente vinhos de alta qualidade e evitar classificações incorretas.

Escolha do modelo final

O modelo escolhido foi o Random Forest. Esta escolha foi baseada no melhor equilíbrio entre as métricas avaliadas. O modelo apresentou a maior “acurácia”, o maior “F1-score”, a maior “precisão” e a maior “ROC-AUC”.

Do ponto de vista de negócio, esse equilíbrio é importante porque o objetivo não é apenas identificar vinhos de alta qualidade, mas também evitar que muitos vinhos comuns sejam classificados incorretamente como superiores.

Assim, o Random Forest se mostrou a alternativa mais adequada para apoiar a tomada de decisão.

Interpretação das variáveis mais importantes

A análise de importância das variáveis do Random Forest indicou que as características mais relevantes para a classificação foram:

- teor alcoólico;
- ácido cítrico;
- sulfatos;
- acidez volátil;
- densidade.

O teor alcoólico foi a variável mais importante para o modelo. Isso sugere que essa característica tem forte contribuição para diferenciar vinhos de alta qualidade dos demais.

Já o ácido cítrico apareceu em segundo lugar, indicando possível associação com frescor e equilíbrio do vinho.

Os sulfatos também apresentaram alta importância, possivelmente por sua relação com estabilidade e preservação do produto.

A acidez volátil foi outra variável relevante, pois valores elevados dessa característica podem prejudicar a percepção sensorial do vinho e afetar negativamente sua qualidade.

A densidade também contribuiu para a classificação, possivelmente por refletir aspectos relacionados à composição geral do vinho, como teor alcoólico e açúcar residual.

Implicações para o processo produtivo

Os resultados indicam que modelos de Machine Learning podem apoiar produtores e enólogos na identificação de padrões físico-químicos associados à qualidade dos vinhos.

O modelo não substitui a avaliação de especialistas, mas pode funcionar como uma ferramenta complementar para orientar decisões no processo produtivo.

Na prática, os insights obtidos podem ajudar no acompanhamento de variáveis como teor alcoólico, acidez, sulfatos, ácido cítrico e densidade.

Essas informações podem apoiar ajustes no processo de produção, contribuir para maior padronização da qualidade e auxiliar na identificação antecipada de lotes com maior potencial de avaliação positiva.

Conclusão

O projeto demonstrou que é possível utilizar dados físico-químicos para classificar vinhos de alta qualidade ou baixa/média qualidade.

A análise exploratória mostrou que a base possui predominância de vinhos com notas intermediárias e menor quantidade de vinhos de alta qualidade, caracterizando um problema desbalanceado.

Foram treinados e comparados três modelos de classificação. O Random Forest apresentou o melhor desempenho geral, com “acurácia” de 91,7%, “F1-score” de 67,8% e “ROC-AUC” de 90,8%.

As variáveis mais importantes para o modelo foram teor alcoólico, ácido cítrico, sulfatos, acidez volátil e densidade.

Como conclusão, o modelo desenvolvido pode ser utilizado como ferramenta de apoio à decisão, ajudando a indústria vitivinícola a entender quais características físico-químicas estão mais associadas à qualidade final dos vinhos.

O uso de Machine Learning não elimina a necessidade da avaliação sensorial, mas complementa esse processo com uma visão mais objetiva, escalável e orientada por dados.

Limitações e Trabalhos Futuros

Apesar dos bons resultados, o projeto apresenta limitações. A primeira é que o modelo foi treinado com uma base específica e pode não generalizar perfeitamente para outros tipos de vinho, regiões, safras ou processos produtivos. Antes de usar o modelo em ambiente real, é necessário validar seu desempenho com dados da própria empresa.

A segunda limitação é a ausência de variáveis sensoriais e contextuais. Características como uva, safra, região de origem, tempo de barrica, temperatura de fermentação e avaliação aromática poderiam melhorar a capacidade explicativa do modelo.

A terceira limitação é o desbalanceamento das classes. A quantidade menor de vinhos de alta qualidade torna a avaliação mais sensível e pode exigir estratégias adicionais, como ajuste de limiar, reamostragem ou validação com novas bases.

Como trabalhos futuros, recomenda-se testar técnicas de balanceamento, otimizar hiperparâmetros, avaliar modelos adicionais e aplicar métodos de interpretabilidade mais robustos.

Também seria relevante criar um dashboard para acompanhar previsões, variáveis críticas e evolução da qualidade por lote.

O caminho natural é transformar o notebook em uma pipeline reproduzível, documentada e versionada, garantindo que novas amostras possam ser avaliadas de forma padronizada.

Referências

BREIMAN, L. Random forests. Machine Learning, v. 45, p. 5-32, 2001.

CORTEZ, P.; CERDEIRA, A.; ALMEIDA, F.; MATOS, T.; REIS, J. Modeling wine preferences by data mining from physicochemical properties. Decision Support Systems, v. 47, n. 4, p. 547-553, 2009.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The elements of statistical learning: data mining, inference, and prediction. 2. ed. New York: Springer, 2009.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. An introduction to statistical learning. 2. ed. New York: Springer, 2021.

KOTLER, P.; KELLER, K. L. Administração de marketing. 14. ed. São Paulo: Pearson Education do Brasil, 2012.

PROVOST, F.; FAWCETT, T. Data science for business. Sebastopol: O'Reilly Media, 2013.

SCIKIT-LEARN DEVELOPERS. scikit-learn: machine learning in Python. Documentação oficial, 2026.

FIAP. Tech Challenge - Classificando a qualidade de vinhos com Machine Learning. Material do curso, 2026.

Observação: este relatório foi elaborado a partir dos resultados exportados do notebook do projeto, incluindo métricas dos modelos, comparação visual e importância das variáveis do Random Forest.